


Transformers en E-commerce

Predicción de BTR





El recorrido

- 1 Problema y entrada
- 2 Arquitectura y fusión
- 3 Tokenizador
- 4 Encoder
- 5 Panorama de ablaciones
- 6 Resultados
- 7 Qué aprendió
- 8 Cierre



OBJETIVO

Predecir el BTR de un producto en base a toda la información que tenemos

**BUY THROUGH RATE
(BTR)**

Probabilidad de que un producto mostrado en una query termine en compra

PRIMER VISTAZO

Una fila es un producto mostrado en una búsqueda

Filas (impresiones)	10,000
query_id	2,012
Productos por búsqueda	1 a 8, mediana 5
Target	bought, binario
BTR global	13,0% – 1.301 de 10.000

- query_id:
 - Funciona como identificador de la búsqueda
 - Combinación de los parámetros filter_category, filter_storage_type, filter_price_min y filter_price_max
 - No representa una búsqueda puntual. Una query abarca una entre 488 y 728 días.





QUÉ SACAMOS Y POR QUÉ



CART

No hay compra sin carrito y no se sabe al momento de recomendar el producto

FILTER_CATEGORY ·
FILTER_STORAGE_TYPE ·
FILTER_PRICE_MAX ·
FILTER_PRICE_MIN

Coinciden con los productos mostrados

BRAND · COUNTRY_OF_ORIGIN ·
STORAGE_TYPE · UNIT_OF_MEASURE ·
NET_WEIGHT_OZ · VOLUME_IN3 ·
NUTRITION_SCORE · PRODUCTS_IN_QUERY
· CAMPOS DERIVADOS DE FECHAS

El analisis nos da a entender que la separación no supera la variabilidad esperable por el azar

PACKAGE_SIZE

Mezcla peso, volumen y cantidad:


- peso y el volumen → net_weight_oz
- ct redundante con category.



NUESTRO ANÁLISIS


1. Medimos la separación: **BTR máximo – BTR mínimo**.
Ejemplo: *storage_type*: 13,2% Ambient – 12,2% Frozen = 1,0 pp
2. Barajamos **bought** 10.000 veces
 - Conservamos los grupos y sus tamaños.
 - Cada barajada produce una separación por azar.
3. Calculamos el **p-value**: proporción de barajadas que igualan o superan la separación observada.
 - **$p \leq 0,05$** : evidencia de señal.
 - **$p > 0,05$** : compatible con azar.

ANÁLISIS



PARTICIONADO

- 20% como **test**
- 80% como **training**(80%) y **validación**(20%)
- **Group**: todas las filas con el mismo **query_id** van al mismo grupo
- **Stratified**: cada parte con la misma proporción de compras que el total (5 folds)






La arquitectura

Dos torres, una tabular y una de texto. La de texto es un encoder tipo BERT y la tabular, un MLP


Configuración:

d_model 64 · 1 encoder · 4 heads · FFN ×4 (64→256→64) · dropout 0,1 ·
pooling [CLS] · positional learned.
loss BCEWithLogitsLoss · corte por AP · 150 épocas · paciencia 10


La Arquitectura




Torre de Texto




Torre de Texto



Torre de Texto



Torre de Texto



Torre Tabular

TORRE TABULAR

category · allergens · price_position
categóricas + numérica

Codificación tabular
one-hot(12) · one-hot(8)
piecewise-linear(10)


x_tab (B, 30)

MLP

Linear(30→32) → ReLU → Dropout
→ Linear(32→16)

h_tab (B, 16)

Fusión Tardía



Datos de entrada

¿Cómo entra?

T

Texto: title · description · ingredients

WordPiece entrenado sobre el corpus. [CLS] A [SEP] B [SEP] C [SEP], 68 posiciones.

C

Categorías: category (12) · allergens (8)

One-hot

N

Numérica: price_position


Piecewise-linear sobre 10 bins

Tamaño de vector final: $x_{\text{tab}} \in \mathbb{R}^{30}$

Deep-dive del tokenizer

Qué hicimos: Evaluamos distintas estrategias de tokenización, analizando qué elementos conservar y cómo dividir el texto en tokens

Objetivo: Entender cómo distintas formas de construir el vocabulario y segmentar el texto afectan la representación de entrada y el aprendizaje del modelo.





Wholeword vs
Wordpiece

Con vs sin signos de
puntuación

Con vs sin paréntesis

Deep-dive del tokenizer






Deep-dive del embedder


Qué hicimos: variamos el positional encoding y el LayerNorm + Dropout de cierre de la capa de embedding, cada uno por separado

Objetivo: entender qué parte de "cómo se arma el vector antes del encoder" le importa al modelo



Deep-dive del embedder






Variaciones en el transformer


Qué hicimos: Comparamos los resultados de nuestra arquitectura base contra los de una arquitectura con variaciones en algunos parámetros

Objetivo: Entender el impacto de cambios en la arquitectura / transformaciones en el resultado

Variaciones en el transformer



Variaciones en el transformer









Resultados

Distribución de la atención del [CLS]

Cuanta atencion se lleva cada grupo



Cuanta atencion se lleva cada token







Evaluación modelo final

ROC-AUC = 0,972


PR-AUC = 0,854

- 2.002 filas nuevas
- BTR del dataset: **13,01 %**



CONCLUSIONES

- **Una arquitectura más compleja no implica que de mejor:** las configuraciones más simples obtuvieron mejores resultados
- Los componentes de la **etapa final** tuvieron mayor impacto que aumentar la complejidad del Transformer
- El MLP de salida tuvo el mayor **impacto individual:** la interacción entre las representaciones de texto y las variables tabulares es relevante
- Los **paréntesis** del título aportan información al modelo: conservarlos mejoró el average precision, mientras que cambiar entre WordPiece y palabras completas prácticamente no tuvo efecto
- El efecto de los paréntesis depende de la información posicional.
- La **atención del [CLS]** muestra que observar dónde atiende el modelo no equivale necesariamente a identificar qué información es causalmente útil
- Más que escalar la arquitectura, el foco debe estar en plantear bien el problema



PERSONALIZACIÓN POR USUARIO

- **Gap actual:** el dataset es content-based; no contiene información sobre el usuario que realizó cada búsqueda.
- **Propuesta:** agregar una tercera torre con un **Transformer secuencial con self-attention causal** sobre el historial anterior al evento que se quiere predecir del usuario.
- **Evento histórico:** contenido del producto (32) + $\log(1 + \Delta t)$ (1) + acción one-hot (3) $\rightarrow$ Linear(36 $\rightarrow$ 32)
- **Información temporal:** orden de los eventos + Δt real.
- **Fusión:** [h_text, h_tab; h_user] (112) $\rightarrow$ MLP $\rightarrow$ BTR.
- **Riesgos:** cold-start - historiales cortos - overfitting



Gracias!

GRUPO 2