



TRANSFORMERS EN E-COMMERCE

PREDICCIÓN DE BTR





TABLE OF CONTENT

1

EDA

2

PARTICIÓN

3

ARQUITECTURA

4

REPRESENTACIONES

5

CONFIGURACIONES
A/B/C

6

EVALUACIÓN

7

PERSONALIZACIÓN

8

CONCLUSIONES



OBJETIVO

Predecir el BTR de un producto en base a toda la información que tenemos

**BUY THROUGH RATE
(BTR)**

Probabilidad de que un producto mostrado en una query termine en compra

PRIMER VISTAZO

Una fila es un producto mostrado en una búsqueda

Filas (impresiones)	10,000
query_id	2,012
Productos por búsqueda	1 a 8, mediana 5
Target	bought, binario
BTR global	13,0% – 1.301 de 10.000

- query_id:
 - Funciona como identificador de la búsqueda
 - Combinación de los parámetros filter_category, filter_storage_type, filter_price_min y filter_price_max
 - No representa una búsqueda puntual. Una query abarca una entre 488 y 728 días.





QUÉ SACAMOS Y POR QUÉ

CART

No hay compra sin carrito y no se sabe al momento de recomendar el producto

FILTER_CATEGORY ·
FILTER_STORAGE_TYPE ·
FILTER_PRICE_MAX ·
FILTER_PRICE_MIN

Coinciden con los productos mostrados

BRAND · COUNTRY_OF_ORIGIN ·
STORAGE_TYPE · UNIT_OF_MEASURE ·
NET_WEIGHT_OZ · VOLUME_IN3 ·
NUTRITION_SCORE · PRODUCTS_IN_QUERY
· CAMPOS DERIVADOS DE FECHAS

El analisis nos da a entender que la separación no supera la variabilidad esperable por el azar

PACKAGE_SIZE

Mezcla peso, volumen y cantidad:


- peso y el volumen → net_weight_oz
- ct redundante con category.



NUESTRO ANÁLISIS


1. Medimos la separación: **BTR máximo – BTR mínimo**.
Ejemplo: *storage_type*: 13,2% Ambient – 12,2% Frozen = 1,0 pp
2. Barajamos ***bought*** 10.000 veces
 - Conservamos los grupos y sus tamaños.
 - Cada barajada produce una separación por azar.
3. Calculamos el **p-value**: proporción de barajadas que igualan o superan la separación observada.
 - **$p \leq 0,05$** : evidencia de señal.
 - **$p > 0,05$** : compatible con azar.

ANÁLISIS



PARTICIONADO

- 20% como **test**
- 80% como **validación** (80%) y **training** (20%)
- **Group:** todas las filas con el mismo **query_id** van al mismo grupo
- **Stratified:** cada parte con la misma proporción de compras que el total (5 folds)





LA ARQUITECTURA

Encoder-only, como BERT

Buscamos representar una entrada

- Clasificamos combinando todas las posiciones con mean pooling + capa lineal + sigmoide
- Cada posición ve a todas las demás (sin máscara)



ENTRADA DE DATOS

TEXTO

Title · Description · Ingredients

Tabla de embeddings

CATEGÓRICAS


Allergens · Category

Un vector por nivel

NUMÉRICAS

Price position

Calculo del vector



CALCULO DEL VECTOR NUMERICO



AFÍN

La más simple: el vector es proporcional al valor

$$e = \text{valor} \cdot w + b$$

BUCKETS

Cada franja de precio tiene su propio vector, libre e independiente de las franjas vecinas

$$e = \text{tabla}[\text{decil}(\text{valor})]$$

PIECEWISE-LINEAR

En vez de saltar de golpe entre franjas, mezcla las dos vecinas según qué tan cerca estás de cada una.

$$e = (1-t) \cdot \text{tabla}[i] + t \cdot \text{tabla}[i+1]$$

PERIODIC

Convierte valores en ondas que giran a distintas velocidades, para captar tanto diferencias chicas como la tendencia general.

$$e = [\sin(c \cdot x), \cos(c \cdot x), \dots]$$

CALCULO DEL VECTOR CATEGÓRICO

ONE HOT

- Cada categoría → columna binaria (1/0).
- Dimensión = cantidad de categorías únicas.
- No usa bought → sin riesgo de fuga.

TARGET ENCODING SUAVIZADO

Cada categoría → BTR promedio de esa categoría. Una sola columna. Se calcula solo con train, fold por fold, para evitar fuga.



CALCULO DEL VECTOR DE TEXTO



BOLSA BINARIA

1 columna por palabra. Un texto vale 1 si contiene la palabra y 0 si no. Todas las palabras tienen, inicialmente, la misma importancia.

TF-IDF

1 columna por palabra. Componente IDF baja el peso de términos muy comunes en todos los textos y sube el de términos más raros y específicos.



ANÁLISIS DE MODELOS

Comparáremos algunos modelos y variamos
parámetros para entender qué modelo nos da
los mejores resultados

FLUJO DE ANÁLISIS

Calculo de vector

Embeddings

Profundidad, Ancho, Heads

Fine-tuning





CONFIGURACIONES

A

Regresión logística variando los campos
ingresados

B

Transformer · Capas=0, d_model=64, n_heads=4 ·
pooling=mean · positional=none, dropout=0.1 · lr=1e-4,
weight_decay=0.01 · epochs=60 · patience=10,
batch_size=64

C

Igual a B salvo n_layers=1 (**1 bloque self-attention**)

¿Qué responde?

¿Cuánto predice el método más
simple y barato posible?



¿Aporta algo aprender la
representación en vez de bolsa
de palabras?

¿Aporta algo la atención por
sobre el promedio simple de B?



Configuración A
Entender la calidad de la
representación


CALCULO DE VECTOR (TEXTO Y CATEGÓRICO)



PR-AUC (AP), media entre folds +/- desvío




CALCULO DE VECTOR (NUMÉRICO)







Configuración A
Entender la calidad de la
representación

PRESICIÓN DE MODELOS






ARQUITECTURA EN DETALLE






ARQUITECTURA EN DETALLE





ARQUITECTURA EN DETALLE



RESULTADOS CON TEST

LA BARRA (A*)



- Regresión logística
- **Parámetros:** 51
- **Categoricas:** Allergens · Category · clave extraída
- **Numéricas:** price_position

MODELO FINAL: C*

- **Transformer**
- **Capas de atención:** 2
- **d_model:** 96
- **n_heads:** 4
- **Learning Rate:** 2e-4
- **Parámetros:** 277.345
- **Dropout:** 0,3
- **Positional:** none
- **Pooling:** promedio
- **Embeddings:** Piecewise




ROC Y PR





CALIBRACIÓN

Calibración en el test: BTR predicho contra observado



PRECISIÓN Y LIFT @K

Precision y lift en el tope del ranking (test)





PERSONALIZACIÓN POR USUARIO

- **Gap actual:** el dataset es content-based, no tiene información acerca del usuario que realizó la búsqueda
- **Propuesta:** un encoder de secuencia con self-attention causal sobre el historial del usuario.
- Codificación por **Δt real**.
- Se utilizan ambos vectores para el modelo:
[vector_producto ; vector_usuario]
- **Riesgos:** cold-start (usuario desconocido), costo computacional extra, mayor riesgo de overfitting con historiales cortos.

CONCLUSIONES

- La **atención** recién aporta una vez que el resto de la arquitectura está calibrada a su alrededor.
- La atención mejora al **Transformer** respecto de versiones anteriores pero **no logra superar al modelo lineal simple** (A).
- Si se promociona solo una porción chica del catálogo, el modelo simple gana con margen. La diferencia se achica a medida que se promociona más catálogo.
- no nos sirvió por la naturaleza de los datos
- análisis de los últimos gráficos
- más queries resulta en un modelo más estable pero exceso resulta en un modelo que predice mal
- La mayor parte de los productos tiene probabilidad de compra casi nula



GRACIAS!

GRUPO 2

